

# Регрессия и стохастический градиентный спуск

## Необходимые сведения

Иванов И.Е., Петюшко А.А.

МГУ

3 марта 2020 г.

- 1 Регрессия
- 2 Коэффициент детерминации
- 3 Стохастический градиентный спуск
- 4 Численная производная
- 5 Итераторы

## Постановка задачи и допущения

- **Обучающая выборка:**  $X_{train} = \{(x^{(1)}, y_1), \dots, (x^{(N)}, y_N)\}$
- **Пространства признаков и ответов:**  $X = \mathbb{R}^n$ ,  $Y = \mathbb{R}$
- $a(x) = f_w(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$ , где  $w = (w_0, w_1, \dots, w_n)^T \in \mathbb{R}^{n+1}$  — параметры модели.
- Удобно писать в векторном виде

$$a(x) = w^T \cdot x,$$

где  $x = (x_0, x_1, \dots, x_n)^T$  и  $x_0 = 1$ .

# Линейная регрессия: аналитическое решение

## Метод наименьших квадратов

- **Функция потерь:**  $L(w, X_{train}) = MSE(w, X_{train}) = \frac{1}{N} \sum_i (w^T \cdot x^{(i)} - y_i)^2$
- **Задача:** найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Теорема

Решением задачи  $\arg \min_w (\frac{1}{N} \sum_i (w^T \cdot x^{(i)} - y_i)^2)$  является  $\hat{w} = (X^T X)^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_j^{(i)}$ ,  $y = (y_1, \dots, y_N)$ .

## L2-регуляризация

- **Функция потерь:**

$$L(w, X_{train}) = MSE(w, X_{train}) + \gamma \sum_{i=0}^n w_i^2 = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2$$

- Перенормировка:  $\alpha = N\gamma$
- **Задача:** найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Теорема

Решением задачи  $\arg \min_w (\sum_{i=1}^{\ell} (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n w_i^2)$  является

$\hat{w} = (X^T X + 2\alpha I_n)^{-1} \cdot X^T \cdot y$ , где  $X_{i,j} = x_j^{(i)}$ ,  $y = (y_1, \dots, y_{\ell})$ ,  $I_n$  — единичная матрица.

## L1-регуляризация

- Функция потерь:

$$L(w, X_{train}) = MSE(w, X_{train}) + \gamma \sum_{i=0}^n |w_i| = \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i|$$

- Перенормировка:  $\alpha = N\gamma$
- Задача: найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Свойства

- Нет аналитического решения

## L1-регуляризация и L2-регуляризация

- **Функция потерь:**  $L(w, X_{train}) = MSE(w, X_{train}) + \gamma_1 \sum_{i=0}^n |w_i| + \gamma_2 \sum_{i=0}^n w_i^2 =$   
$$= \sum_i (w^T \cdot x^{(i)} - y_i)^2 + \alpha \sum_{i=0}^n |w_i| + \beta \sum_{i=0}^n w_i^2$$
- Перенормировка:  $\alpha = N\gamma_1, \beta = N\gamma_2$
- **Задача:** найти  $\hat{w} = \arg \min_w (L(w, X_{train}))$

## Свойства

- Нет аналитического решения

# Коэффициент детерминации

- Пусть  $Y = \{y_1, \dots, y_N\}$  — множество правильных ответов
- $Y_{pred} = \{y_{pred1}, \dots, y_{predN}\}$  — множество предсказанных ответов

## Коэффициент детерминации

$R^2$ -коэффициент (определяющий качество предсказания):

$$R^2 = 1 - \frac{\sum_i (y_i - y_{predi})^2}{\sum_i (y_i - \frac{1}{N} \sum_j y_j)^2}$$

**Замечание.**  $-\infty < R^2 \leq 1$ . Идеальное предсказание дает  $R^2 = 1$ .



# Классический градиентный спуск

- **Функция потерь** для линейной регрессии (без регуляризации):  
$$L(w, X_{train}) = \frac{1}{N} \sum_i (w^T \cdot x^{(i)} - y_i)^2 = \frac{1}{N} \sum_i L(w, x^{(i)}) = \frac{1}{N} \sum_i L_i(w)$$
- **Задача:** минимизировать  $L(w, X_{train})$  путем обучения весов  $w$ :  $L(w, X_{train}) \rightarrow \min_w$

## Численная оптимизация методом градиентного спуска

- **Начальное приближение:**  $w^{(0)} := 0$
- **Итерация алгоритма:**  $w^{(t+1)} := w^{(t)} - \eta \cdot \nabla_w L(w^{(t)}, X_{train})$
- **Градиентный шаг:**  $\eta$

**Проблема:** сложно считать в условиях большого количества объектов в обучающей выборке.

# Стохастический градиентный спуск

## Алгоритм стохастического градиентного спуска

- Инициализация весов  $w^{(0)}$
- Инициализация функции потерь  $L(w^{(0)}, X_{train}) := \frac{1}{N} \sum_i L_i(w^{(0)})$

## Итерации

- Выбор объекта  $x_i \in X^m$  (например, случайным образом)
- Вычисление ошибки на данном объекте:  $L_i(w^{(t)})$
- Шаг градиентного спуска:  $w^{(t+1)} := w^{(t)} - \eta \cdot \nabla_w L_i(w^{(t)})$

## Инициализация

- $w_j = 0$
- $w_j = \text{rand}(-\frac{1}{2n}, \frac{1}{2n})$

## Пакетный SGD

**Идея:** на каждом шаге использовать более надежную оценку градиента не на одном примере, а на нескольких

## Итерации

- Выбор подмножества объектов мощности  $1 < k < N$ :  $J = \{i_1, \dots, i_k\}$
- Вычисление ошибки на этих объектах:  $L_{i_1}(w^{(t)}), \dots, L_{i_k}(w^{(t)})$
- Шаг градиентного спуска:  $w^{(t+1)} := w^{(t)} - \eta \cdot \frac{1}{k} \sum_{j=1}^k \nabla_w L_{i_j}(w^{(t)})$

# Численный градиент

## Численная производная

- Пусть  $x \in \mathbb{R}$
- Используем разложение Тейлора до первого порядка:  $f(x + \delta) \approx f(x) + \delta f'(x)$
- Производная с помощью конечных разностей первого порядка:  $f'(x) \approx \frac{f(x+\delta) - f(x)}{\delta}$
- Для более надежной оценки производной:  $\delta \rightarrow 0, \delta > 0$

## Численный градиент

- Пусть  $x = (x_1, \dots, x_n) \in \mathbb{R}^n$
- Тогда градиентом  $\nabla f(x)$  называется вектор  $\nabla f(x) = (\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n})$
- Частная производная:  $\frac{\partial f(x)}{\partial x_i} \approx \frac{f(x + \delta e_i) - f(x)}{\delta}$ , где  $e_i = (0, \dots, 0, 1, 0, \dots, 0)$  — единичный базисный вектор с 1 на месте  $i$

- Нужны для упрощения навигации по элементам объекта (некоторая коллекция)
- Применяются в цикле “for i in iterator:”
- Имеют достаточно строгий синтаксис
- В задачах подразумевается, что мы будем ходить по обучающей выборке некоторое количество полных раз по кругу, после чего завершаем работу

# Итераторы в Python

```
class mylterator:
    def __iter__(self):
        return self
    def __init__(self, limit):
        self.limit = limit
        self.counter = 0
    def __next__(self):
        if self.counter < self.limit:
            self.counter += 1
            return 1
        else:
            raise StopIteration

iterate = mylterator(3)
for i in iterate:
    print(i)
```

Удачи в решении задач!